

Aplicação de Modelo de Rede Neural Convolucional EEGNet em Dados Eletroencefalográficos de Imagética Motora

Seidi Y. Yamauti

IIN-ELS

Email: seidi.yamauti@edu.isd.org.br

Abstract—O modelo de rede neural convolucional EEGNet foi testado com dados EEG de imagética motora adquiridos através da plataforma EEGBCI. Os resultados de classificação foram comparados com modelos consolidados xDAWN + RG e CSP + LDA, obtendo a mesma acurácia. O respositório deste estudo está disponível em: https://github.com/seidikun/trabalho_final_progamacao

1. Introduction

Interfaces-Cérebro Máquina (ICMs) são uma solução em neuroengenharia que oferece comunicação e capacidades de controle de dispositivos eletromecânicos para pessoas com deficiências motoras severas [1]. Estudos atuais têm utilizado interfaces de propósito-único e que não generalizam para mais que uma tarefa. Por outro lado, o uso de aprendizado profundo (Deep Learning) oferece a possibilidade de desenvolvimento de algoritmos que consigam estabelecer um aprendizado que abranja diversas tarefas em um único modelo [2] e por isso é interessante que haja maior intersecção entre as áreas de ICM e aprendizado de máquina

2. Materiais e Métodos

2.1. EEGNet

O modelo EEGNet é uma rede neural convolucional proposto em [3] e desenvolvido com 3 propriedades:

- 1) Ser aplicável em diversos paradigmas de ICM
- 2) Pode ser treinado com uma quantidade limitada de dados
- 3) Produz características fisiologicamente interpretáveis

O modelo está disponível através da plataforma GitHub no link <https://github.com/vlawhern/arl-eegmodels>

2.2. Dados EEGBCI

Uma plataforma para estudos de ICM para propósitos gerais foi desenvolvida em [4], sendo capaz de combinar diversos tipos de sinais cerebrais, métodos de processamento de sinais, dispositivos de saída e protocolos operacionais. Os dados utilizados no presente estudos foram extraídos através

desta plataforma e estão disponíveis pelo banco de dados PhysioNet [5]

Os dados utilizados foram obtidos do sujeito com id 93, blocos 4,8 e 12, conforme a descrição dos dados para tentativas de imagética motora de mão direita e mão esquerda. O pré-processamento é realizado por meio de filtro digital passa-bandas por janelamento (firwin), com frequência mínima de corte 7Hz e frequência máxima de corte 30Hz. Os dados filtrados EEG são então janelados em torno dos eventos marcados, com 1 segundo antes e 4 segundos após a marcação no sinal, de onde se obtém 45 janelas, sendo 23 de imagética motora utilizando a mão esquerda e 22 de imagética motora utilizando a mão direita.

2.3. Algoritmos Consolidados de Classificação de Imagética Motora em dados EEG

Para efeito de comparação com o modelo EEGNet, dois algoritmos foram utilizados para classificação de imagética motora em EEG e suas respectivas acurácias extraídas: o modelo de filtro xDAWN com aplicação de geometria riemanniana é proposta em [6] [7] e obteve o primeiro lugar na competição Kaggle BCI <http://github.com/alexandrebarachant/bci-challenge-ner-2015> para detecção de potenciais erros de aquisição de dados em uma tarefa de soletramento usando o paradigma P300 em ICM e foi utilizado para comparação com a EEGNet em [3]. Já o modelo CSP + LDA [8] é comumente utilizado para classificação de imagética motora em dados EEG

3. Resultados

Os três modelos obtiveram acurácia de 100% sobre os dados EEGBCI de imagética motora. O modelo EEGNet foi testado com diversas configurações, demonstrando instabilidade sobre os dados, o que será discutido na seção 4

4. Discussão

O modelo EEGNet apresenta a perspectiva de aprendizado de máquina profundo, de forma a substituir o modelo clássico que envolve especificação de extração de características e especificação de classificação. Nesta perspectiva,

as duas fases estão contidas em um único modelo, possibilitando a atualização de parâmetros de forma genérica. No estudo com dados de imagética motora, a EEGNet obteve a mesma acurácia que modelos clássicos, evidenciado como o aprendizado de máquina profundo pode conter as especificações de generalidade e alta performance. Porém, foi notado que a acurácia de predição da EEGNet é sensível aos valores de parâmetros de definição, necessitando de um estudo mais aprofundado sobre sua explicabilidade

5. Conclusão

O modelo EEGNet foi aplicado em dados EEG de imagética motora com os mesmos parâmetros citados em [3], obtendo resultado comparável a modelos consolidados para a classificação do mesmo tipo de paradigma em ICM. Estudos futuros podem incluir a explicabilidade do modelo em relação a características fisiologicamente prováveis e estudo com dados mais extensos, envolvendo mais sujeitos e protocolos de treino diversos.

References

- [1] L. F. Nicolas-Alonso and J. Gomez-Gil, "Brain computer interfaces, a review," *sensors*, vol. 12, no. 2, pp. 1211–1279, 2012.
- [2] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [3] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, "Eegnet: a compact convolutional neural network for eeg-based brain–computer interfaces," *Journal of neural engineering*, vol. 15, no. 5, p. 056013, 2018.
- [4] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, "Bci2000: a general-purpose brain-computer interface (bci) system," *IEEE Transactions on biomedical engineering*, vol. 51, no. 6, pp. 1034–1043, 2004.
- [5] A. L. Goldberger, L. A. Amaral, L. Glass, J. M. Hausdorff, P. C. Ivanov, R. G. Mark, J. E. Mietus, G. B. Moody, C.-K. Peng, and H. E. Stanley, "Physiobank, physiotoolkit, and physionet: components of a new research resource for complex physiologic signals," *circulation*, vol. 101, no. 23, pp. e215–e220, 2000.
- [6] B. Rivet, A. Souloumiac, V. Attina, and G. Gibert, "xdawn algorithm to enhance evoked potentials: application to brain–computer interface," *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 8, pp. 2035–2043, 2009.
- [7] M. Congedo, A. Barachant, and A. Andreev, "A new generation of brain-computer interface based on riemannian geometry," *arXiv preprint arXiv:1310.8115*, 2013.
- [8] Z. J. Koles, "The quantitative extraction and topographic mapping of the abnormal components in the clinical eeg," *Electroencephalography and clinical Neurophysiology*, vol. 79, no. 6, pp. 440–447, 1991.